UNIVERSIDAD DEL VALLE DE GUATEMALA

Data Science



Proyecto 2: Resultados

Clasificación degenerativa de la columna lumbar (RSNA 2024)

Repositorio: https://github.com/Albu231311/Proyecto2-DS.git

Erick Guerra - 23208
Fabian Morales - 23267
Olivier Viau - 23544
Carlos Alburez - 231311

GUATEMALA, 19 de octubre del 2026

1. Introducción

La enfermedad degenerativa de la columna lumbar es una de las causas más comunes de dolor de espalda baja y ciática en la población adulta. No es una única patología, sino un conjunto de alteraciones estructurales y metabólicas asociadas al envejecimiento, al desgaste biomecánico o a traumatismos repetitivos sobre las vértebras, los discos intervertebrales y las articulaciones facetarias de la parte baja de la espalda (Cleveland Clinic, 2023).

El diagnóstico depende de que un radiólogo interprete manualmente resonancias magnéticas en tres planos distintos (sagital T1, sagital T2 y axial T2), evaluando 5 condiciones en 5 niveles vertebrales cada una, es decir, 25 evaluaciones por paciente. Este proceso es lento, especializado y sujeto a variabilidad entre observadores (Hashim, 2006). Por eso hay un interés creciente en sistemas de apoyo basados en aprendizaje automático que ayuden a los especialistas a priorizar los casos más graves.

Este informe presenta el trabajo realizado para el reto **RSNA 2024 Lumbar Spine Degenerative Classification**, organizado por la Radiological Society of North America en Kaggle (Radiological Society of North America, 2024). El problema consiste en clasificar la severidad de cinco condiciones degenerativas (estenosis del canal espinal, estrechamiento foraminal izquierdo y derecho, y estenosis subarticular izquierda y derecha) en cinco niveles vertebrales, de L1/L2 a L5/S1. Cada combinación de condición y nivel se clasifica en una de tres clases: Normal/Mild, Moderate o Severe.

A lo largo del documento se describe la investigación previa sobre algoritmos usados en problemas similares, la limpieza y el análisis exploratorio de los datos, la construcción y el ajuste de cinco modelos (una línea base, tres modelos de árboles sobre la información tabular de cada anotación y una red neuronal convolucional ResNet50 sobre recortes de la imagen), la comparación de su rendimiento y la aplicación interactiva que se construyó para probarlos con datos nuevos. Al final se presentan las conclusiones respecto a cada objetivo.

2. Objetivos

2.1 Objetivo general

Desarrollar un sistema basado en aprendizaje automático que clasifique la severidad de cinco condiciones degenerativas de la columna lumbar a partir de resonancias magnéticas y de la información asociada a cada anotación, e integrarlo en una aplicación interactiva que permita usarlo con datos nuevos.

2.2 Objetivos específicos

- Limpiar, integrar y analizar los datos del reto para identificar su calidad, el balance entre clases y los patrones de severidad por condición y por nivel vertebral.
- Revisar la literatura científica sobre clasificación de estenosis lumbar en resonancia magnética para seleccionar los algoritmos más adecuados.
- Entrenar y ajustar modelos de árboles de decisión, Random Forest y Gradient Boosting sobre la información tabular, y una red convolucional ResNet50 sobre recortes de la imagen.
- Evaluar y comparar los modelos con métricas apropiadas para clases desbalanceadas, junto con sus tiempos de entrenamiento y de predicción.
- Construir una aplicación que prepare automáticamente una entrada nueva, la clasifique con los modelos entrenados y muestre de forma interactiva los datos y el rendimiento de cada algoritmo.

3. Marco teórico

3.1 Enfermedad degenerativa de la columna lumbar

La enfermedad degenerativa de la columna lumbar no es una única patología, sino un conjunto de alteraciones estructurales y metabólicas asociadas al envejecimiento, al desgaste biomecánico o a traumatismos repetitivos sobre las vértebras, los discos intervertebrales y las articulaciones facetarias de la parte baja de la espalda. A medida que el cuerpo envejece, los discos intervertebrales pierden contenido hídrico y elasticidad, lo que reduce su capacidad para amortiguar impactos. Esto causa varios problemas, pero principalmente un dolor crónico en la espalda (Cleveland Clinic, 2023).

La columna lumbar está formada por cinco vértebras (L1 a L5) que se articulan con el sacro (S1). Entre cada par de vértebras hay un disco intervertebral, y a cada segmento se le nombra por las dos vértebras que lo limitan, por ejemplo L4/L5. Los cambios degenerativos estrechan los espacios por donde pasan la médula y las raíces nerviosas, lo que se conoce como estenosis (Katz y Harris, 2008).

3.2 Diagnóstico por resonancia magnética

Para diagnosticar esta enfermedad se realiza una resonancia magnética y se analizan las imágenes, lo que permite ver los discos, la médula y las raíces para identificar claramente el problema (Hashim, 2006). El análisis se hace en tres tipos de secuencia:

- **Secuencia sagital T2:** muestra el líquido cefalorraquídeo. Es esencial para evaluar la estenosis del canal central y la hidratación de los discos intervertebrales.
- **Secuencia sagital T1:** proporciona excelente detalle de la anatomía ósea, la médula ósea y la grasa dentro de los forámenes neurales. Permite identificar con claridad el estrechamiento foraminal.
- **Secuencia axial T2:** son cortes transversales de la columna. Son cruciales para medir el área transversal del canal espinal, evaluar el grado de hipertrofia facetaria y observar el estrechamiento del receso lateral.

Los criterios radiológicos clave que evalúa el médico incluyen el área de sección transversal del canal espinal, el borramiento o la preservación de la grasa epidural e intraforaminal, y la deformación o compresión de la teca dural y de las raíces nerviosas.

Las imágenes de resonancia se guardan en formato DICOM (Digital Imaging and Communications in Medicine), un estándar que almacena en un mismo archivo los valores de los píxeles y metadatos como la orientación del corte, el número de instancia y el tamaño de la imagen (Mildenberger et al., 2002). En el conjunto de datos del reto, las series aparecen como Sagittal T1, Sagittal T2/STIR y Axial T2. A diferencia de una fotografía, la intensidad de los píxeles no tiene una escala fija, por lo que siempre hay que normalizarla antes de usarla en un modelo.

3.3 Condiciones evaluadas en el reto RSNA 2024

Los datos de la RSNA están catalogados para encontrar tres enfermedades distintas y el lado en que se presentan, por lo que se clasifican en cinco condiciones. Cada una se gradúa en tres niveles de severidad (Radiological Society of North America, 2024):

A. Estenosis del canal espinal central (Spinal Canal Stenosis). Es el estrechamiento del canal vertebral principal por donde descienden el saco dural y las raíces nerviosas de la cola de caballo (cauda equina). Se debe al abombamiento del disco, a la formación de osteofitos y a la hipertrofia del ligamento amarillo.

- **Normal/Leve:** espacio de líquido cefalorraquídeo preservado alrededor de las raíces.
- **Moderado:** obliteración parcial del espacio subaracnoideo, con compresión leve del saco dural.
- **Severo:** obliteración completa del líquido cefalorraquídeo; las raíces nerviosas se agrupan y se comprimen severamente.

B. Estenosis subarticular izquierda y derecha (Subarticular Stenosis). Ocurre en la región del receso lateral, justo antes de que la raíz nerviosa entre al foramen intervertebral. Está delimitada por el disco por delante y por la articulación facetaria por detrás.

- **Normal/Leve:** receso amplio; la raíz transita libremente.
- **Moderado:** aplanamiento o leve pinzamiento de la raíz nerviosa.
- **Severo:** compresión severa o desplazamiento directo de la raíz nerviosa contra la faceta o un osteofito.

C. Estenosis foraminal izquierda y derecha (Neural Foraminal Narrowing). Es el estrechamiento del agujero de conjunción por donde la raíz nerviosa sale de la columna vertebral. Los radiólogos evalúan la preservación de la grasa perinerviosa (grasa epidural) que rodea la raíz dentro del foramen (Lee et al., 2010).

- **Normal/Leve:** grasa perinerviosa totalmente conservada en los cuatro cuadrantes.
- **Moderado:** obliteración parcial de la grasa, generalmente en sentido horizontal o vertical.
- **Severo:** obliteración total de la grasa alrededor de la raíz nerviosa, con deformación anatómica de la raíz.

En el reto estos grados se nombran Normal/Mild, Moderate y Severe, y se evalúan en los cinco niveles vertebrales, de L1/L2 a L5/S1.

3.4 Procesamiento de imágenes médicas

Antes de entrenar un modelo con imágenes médicas se aplican varios pasos de preparación. Los que se usaron en este proyecto son los siguientes:

- **Normalización de intensidad:** se recortan los valores extremos (por ejemplo, por debajo del percentil 1 y por encima del percentil 99) y se reescalan a un rango de 0 a 1. Esto reduce el efecto de píxeles muy brillantes y hace comparables imágenes de distintos equipos.
- **Recorte de la región de interés:** en lugar de usar toda la imagen, se toma una ventana alrededor del punto anotado. Así el modelo se concentra en la estructura que se evalúa.
- **Redimensionamiento:** las redes preentrenadas esperan un tamaño fijo de entrada, en este caso 224 por 224 píxeles con tres canales.
- **Aumento de datos:** durante el entrenamiento se aplican rotaciones y traslaciones pequeñas y cambios leves de brillo y contraste, para que el modelo no memorice detalles irrelevantes y generalice mejor.

3.5 Algoritmos de aprendizaje automático

Árbol de decisión. Divide los datos con preguntas sucesivas sobre las variables (por ejemplo, si el nivel es L4/L5) hasta llegar a hojas que asignan una clase. Es fácil de interpretar, pero un solo árbol tiende a sobreajustarse si crece demasiado (Quinlan, 1986).

Random Forest. Entrena muchos árboles sobre muestras distintas de los datos y con subconjuntos aleatorios de variables, y combina sus votos. Esto reduce la varianza de un árbol individual y suele dar buenos resultados con poco ajuste (Breiman, 2001).

Gradient Boosting. Construye árboles pequeños de forma secuencial, de modo que cada árbol corrige los errores de los anteriores (Friedman, 2001). En este proyecto se usó la versión por histogramas de scikit-learn, que agrupa los valores continuos en intervalos y es mucho más rápida con muchos datos.

Redes neuronales convolucionales (CNN). Aprenden directamente de los píxeles mediante filtros que detectan bordes, texturas y formas cada vez más complejas (LeCun et al., 2015). Son

la base de la mayoría de los sistemas actuales de análisis de imágenes médicas (Litjens et al., 2017).

ResNet50 y aprendizaje por transferencia. ResNet introduce conexiones residuales que permiten entrenar redes muy profundas sin que el aprendizaje se estanque (He et al., 2016). La versión de 50 capas preentrenada con ImageNet (Deng et al., 2009) ya sabe reconocer patrones visuales generales, por lo que puede adaptarse a imágenes médicas con muchos menos datos que si se entrenara desde cero. Shin et al. (2016) mostraron que este ajuste fino de redes preentrenadas funciona mejor que entrenar desde cero en tareas de detección asistida por computadora.

3.6 Métricas para clases desbalanceadas

Cuando una clase es mucho más frecuente que las demás, la exactitud no es una buena medida: un modelo que siempre responde la clase mayoritaria obtiene una exactitud alta sin aprender nada (Buda et al., 2018). Por eso se usaron las siguientes métricas:

- **F1 macro:** promedio del F1 de cada clase, donde el F1 combina precisión y sensibilidad. Le da el mismo peso a cada clase, sin importar cuántos casos tenga. Fue la métrica principal para elegir modelos.
- **Balanced accuracy:** promedio de la sensibilidad (recall) de cada clase.
- **Recall de Severe:** porcentaje de casos severos que el modelo detecta. Es la métrica de mayor interés clínico, porque un caso grave sin detectar es el error más costoso.
- **Kappa cuadrático:** mide el acuerdo entre la predicción y la etiqueta real, y penaliza más los errores entre clases lejanas (confundir Severe con Normal/Mild) que entre clases vecinas (Cohen, 1968).
- **Log-loss ponderado:** la métrica oficial del reto. Evalúa las probabilidades y pesa los errores con 1, 2 y 4 para Normal/Mild, Moderate y Severe.

3.7 Revisión bibliográfica

Varios trabajos han abordado la clasificación automática de estenosis lumbar en resonancia magnética. Jamaludin et al. (2017) presentaron SpineNet, una CNN que gradúa varios hallazgos degenerativos por disco intervertebral y alcanza un nivel de acuerdo con los radiólogos cercano al que tienen los radiólogos entre sí. Lu et al. (2018) propusieron DeepSPINE, un sistema que

primero localiza y segmenta las vértebras y luego clasifica la estenosis del canal y de los forámenes con una red convolucional, entrenado con más de 4,000 estudios.

Won et al. (2020) usaron redes convolucionales para graduar la estenosis del canal a partir de imágenes centradas en cada nivel, y reportaron un acuerdo con expertos similar al que existe entre radiólogos. Hallinan et al. (2021) desarrollaron un modelo de aprendizaje profundo que detecta y clasifica la estenosis del canal central, del receso lateral y de los forámenes en resonancias lumbares, con un desempeño comparable al de radiólogos especialistas. Bharadwaj et al. (2023) clasificaron la estenosis y la artropatía facetaria en cortes axiales con un modelo de aprendizaje profundo diseñado para que sus decisiones fueran interpretables.

En cuanto al desbalance de clases, Buda et al. (2018) estudiaron su efecto en redes convolucionales y concluyeron que el sobremuestreo de las clases minoritarias es la estrategia más efectiva en la mayoría de los casos. Esto es importante para este problema, en el que los casos severos son una minoría.

De esta revisión se tomaron tres ideas para el proyecto: trabajar con recortes de la imagen centrados en la estructura anotada, usar una red convolucional preentrenada como extractor de características y combinarla con información anatómica (condición y nivel), y compensar el desbalance con pesos de clase y muestreo balanceado. Además, se entrenaron modelos de árboles sobre información tabular como línea base, para medir cuánto aporta realmente la imagen.

4. Metodología

4.1 Pasos seguidos

El trabajo se organizó en las siguientes etapas:

1. Investigación del contexto médico del problema y revisión de trabajos previos.

2. Carga, limpieza e integración de los tres archivos de datos del reto.

3. Análisis exploratorio de la severidad, de las coordenadas de las anotaciones y de las relaciones entre condiciones.

4. División de los datos en conjuntos de entrenamiento, validación y prueba, separando por paciente.

5. Entrenamiento de una línea base y de tres modelos de árboles sobre la información tabular, con ajuste de hiperparámetros en validación.

6. Entrenamiento de una red ResNet50 sobre recortes de las imágenes DICOM, en una GPU de Kaggle.

7. Evaluación de todos los modelos una sola vez en el conjunto de prueba y comparación de resultados.

8. Construcción de la aplicación interactiva y verificación de que el preprocesamiento de la aplicación produce las mismas predicciones que los notebooks de entrenamiento.

4.2 Selección de los conjuntos de entrenamiento, validación y prueba

Cada paciente (identificado por study_id) aporta hasta 25 etiquetas, y las etiquetas de un mismo paciente están relacionadas entre sí. Si un paciente quedara a la vez en entrenamiento y en prueba, el modelo sería evaluado con información que ya vio, y los resultados serían demasiado optimistas. Por eso la división se hizo **por paciente**, con GroupShuffleSplit de scikit-learn y la semilla 42: ningún paciente aparece en más de un conjunto.

Se usó una proporción de 35% para entrenamiento, 35% para validación y 30% para prueba, lo que corresponde a 690, 691 y 593 pacientes (17,006, 17,039 y 14,612 etiquetas). La decisión de reservar un conjunto de prueba amplio se tomó por la clase Severe: con 30% de los pacientes, la prueba incluye 929 casos severos, el doble de los que habría con una división 70/15/15. Esto permite estimar con estabilidad el recall de la clase minoritaria, que es la de mayor interés clínico. La validación, también amplia, se usó para elegir los hiperparámetros y el mejor momento del entrenamiento de la red. Todos los modelos usan exactamente la misma división, de modo que la comparación entre ellos es directa.

4.3 Selección de los algoritmos

Los algoritmos se eligieron con base en la revisión bibliográfica y en lo observado en el análisis exploratorio:

- **Clase mayoritaria:** un modelo que siempre responde Normal/Mild. No aprende nada, pero sirve como piso: cualquier modelo útil debe superarlo en las métricas balanceadas.

- **Árbol de decisión:** es el modelo más interpretable y permite ver qué variables usa para separar las clases.
- **Random Forest y Gradient Boosting:** son los modelos más fuertes para datos tabulares, toleran variables de distinto tipo sin necesidad de escalarlas y permiten compensar el desbalance con pesos de clase.
- **ResNet50 con aprendizaje por transferencia:** los trabajos revisados muestran que las redes convolucionales son el enfoque más efectivo para graduar la estenosis. Se eligió ResNet50 por su buen equilibrio entre capacidad y costo de entrenamiento, y porque está disponible preentrenada con ImageNet.

Los modelos de árboles usan solo la información tabular de cada anotación: condición, nivel, tipo de serie, número de corte y coordenadas del punto. No ven la imagen, por lo que su comparación con la ResNet50 permite medir cuánto aporta el contenido visual.

4.4 Herramientas utilizadas

Recursos de cómputo. La red ResNet50 se entrenó en Kaggle, que ofrece el conjunto de datos completo de la competencia, con todas las imágenes, y una GPU NVIDIA Tesla T4 con 15.6 GB de memoria. El entrenamiento tomó 70.7 minutos. Los modelos de árboles, la limpieza y el análisis exploratorio se ejecutaron en computadoras personales, ya que cada modelo tarda menos de un segundo en entrenarse. La aplicación también corre en una computadora personal, sin necesidad de GPU.

Lenguaje y bibliotecas. Todo el proyecto se desarrolló en Python. Se usaron pandas y NumPy para el manejo de datos; Matplotlib y Seaborn para las figuras estáticas; scikit-learn (Pedregosa et al., 2011) para los modelos de árboles, la división de los datos y las métricas; PyTorch y torchvision (Paszke et al., 2019) para la red ResNet50; pydicom para leer las imágenes DICOM; y Streamlit con Plotly para la aplicación interactiva. El código se versionó en GitHub y los notebooks se trabajaron en Jupyter y en Kaggle.

5. Resultados y análisis de resultados

5.1 Características del conjunto de datos original

El reto proporciona tres archivos tabulares y las imágenes DICOM de cada estudio:

- **train.csv:** 1,975 estudios y 26 columnas, un identificador y 25 etiquetas de severidad (5 condiciones por 5 niveles). Todas las etiquetas son categóricas con los valores Normal/Mild, Moderate y Severe.
- **train_label_coordinates.csv:** 48,692 anotaciones con el estudio, la serie, el número de corte (instance_number), la condición, el nivel y las coordenadas x, y del punto donde el radiólogo marcó el hallazgo.
- **train_series_descriptions.csv:** 6,294 series con su tipo (Sagittal T1, Sagittal T2/STIR o Axial T2).
- **Imágenes DICOM:** organizadas por estudio, serie y corte. Cada archivo es un corte de la resonancia, y el tamaño de las imágenes varía entre estudios.

5.2 Limpieza y preprocesamiento

Se revisó la calidad de los tres archivos antes de usarlos. No se encontraron estudios ni filas duplicadas, y las 25 columnas de severidad usan solo los tres valores esperados. Las categorías de condición, nivel y tipo de serie no tienen errores de escritura. La integridad entre archivos es casi total: solo un estudio de 1,975 no tiene coordenadas y solo tres no tienen los tres tipos de serie.

El 9.4% de los estudios tiene al menos una etiqueta faltante. Los faltantes no están repartidos al azar: se concentran en la estenosis subarticular de los niveles altos (8.3% en L1/L2 y 4.15% en L2/L3), mientras que las demás combinaciones casi no tienen. Se decidió **no imputar** estas etiquetas, porque inventar un diagnóstico introduciría un sesgo clínico; las filas sin etiqueta simplemente no se usaron. Con el criterio del rango intercuartílico se encontró un 1.47% de valores atípicos en x y un 1.84% en y. Al revisarlos por tipo de serie se vio que aparecen en las tres series y se deben a imágenes de mayor tamaño, no a errores, por lo que se conservaron.

Después se unieron los tres archivos para asignar a cada coordenada su tipo de serie y su etiqueta de severidad. El resultado son 48,657 anotaciones etiquetadas (77.3% Normal/Mild, 16.3% Moderate y 6.3% Severe). A partir de ellas se prepararon dos tipos de entrada, como se ilustra en la Figura 1 para el caso de la imagen:

- **Para los modelos de árboles:** 21 variables por anotación. La condición, el nivel, el tipo de serie y el grupo de la condición (canal, foraminal o subarticular) se codificaron con one-hot.

Se agregaron el número de corte, las coordenadas x, y, y una versión normalizada de las coordenadas entre 0 y 1, recortada a los percentiles 1 y 99.

- **Para la ResNet50:** de cada anotación se lee el corte DICOM correspondiente, se normaliza la intensidad con los percentiles 1 y 99, se recorta una ventana de 96 por 96 píxeles centrada en el punto, se amplía a 224 por 224, se copia a tres canales y se escala entre -1 y 1. Además, la red recibe la condición y el nivel codificados con one-hot.

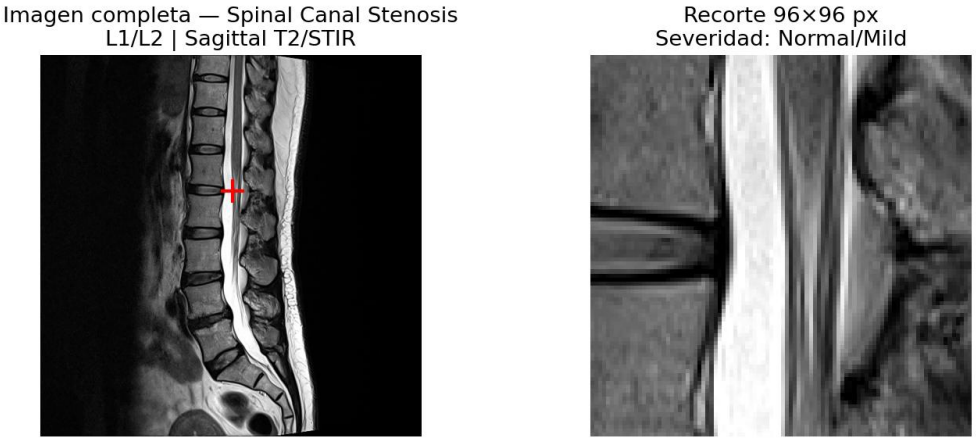


Figura 1. *Ejemplo del preprocesamiento de imagen: corte sagital T2/STIR con el punto anotado (izquierda) y recorte de 96 por 96 píxeles que recibe la red (derecha).*

5.3 Análisis exploratorio

El primer hallazgo es el fuerte desbalance de clases (Figura 2): el 77.4% de las etiquetas son Normal/Mild, el 16.3% Moderate y solo el 6.3% Severe. Un modelo que siempre respondiera Normal/Mild acertaría tres de cada cuatro veces sin aprender nada, por lo que la exactitud no sirve para comparar modelos en este problema y es necesario compensar el desbalance durante el entrenamiento.

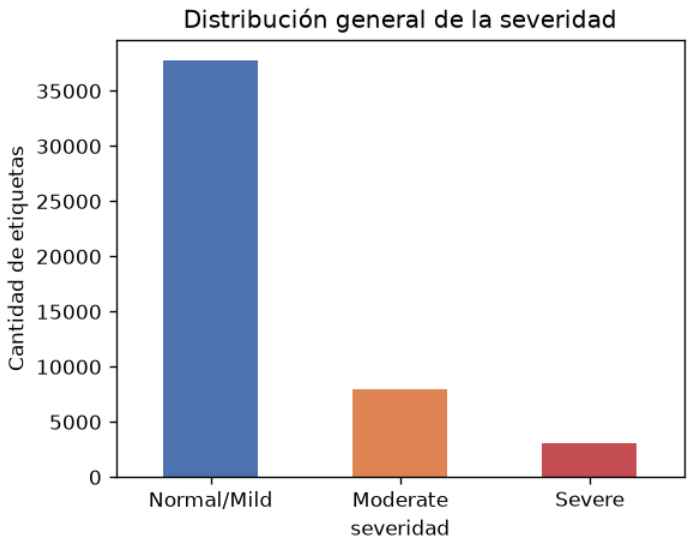


Figura 2. *Distribución general de la severidad en las etiquetas de train.csv.*

El segundo hallazgo es un gradiente claro a lo largo de la columna (Figura 3). La severidad crece desde L1/L2, con 94.9% Normal/Mild y apenas 0.9% Severe, hasta L4/L5, el nivel más comprometido, con 14.7% Severe y 27.8% Moderate. En L5/S1 la severidad baja un poco, pero sigue por encima de los niveles superiores. Esto coincide con la literatura clínica, ya que L4/L5 soporta la mayor carga mecánica de la zona lumbar. Para los modelos, esto significa que el nivel vertebral es una variable con poder predictivo.

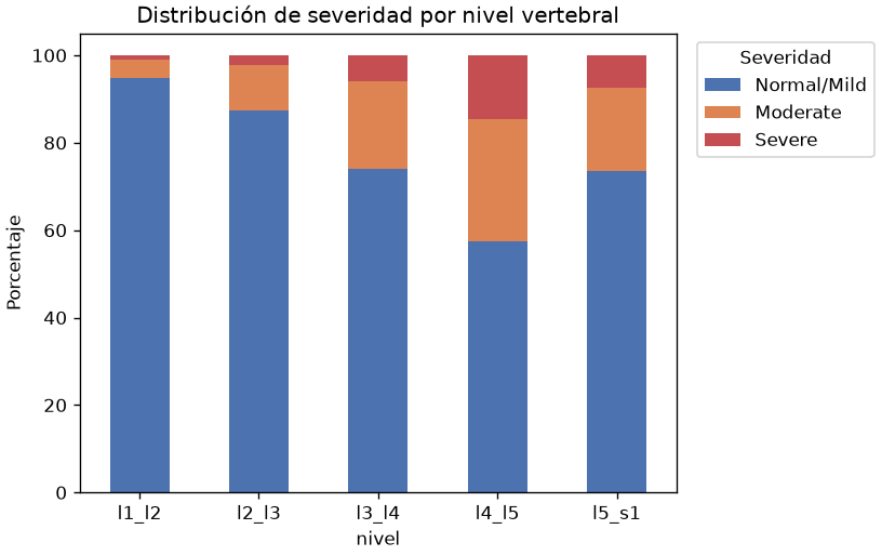


Figura 3. *Distribución de la severidad por nivel vertebral.*

El mapa de calor de severidad promedio por condición y nivel (Figura 4) muestra un detalle que las vistas separadas no dejan ver: casi todas las condiciones llegan a su máximo en L4/L5, pero la estenosis del canal es la excepción, porque cae de 0.38 en L4/L5 a 0.05 en L5/S1, mientras que las condiciones foraminales y subarticulares se mantienen altas en ambos niveles inferiores. La estenosis subarticular es la condición con más casos severos, alrededor de 9.5%.

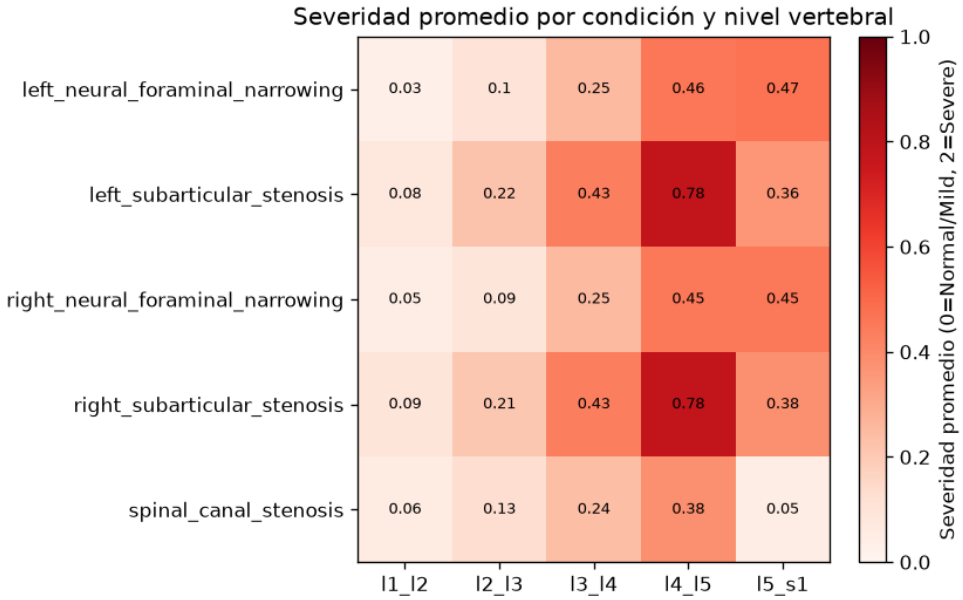


Figura 4. *Severidad promedio por condición y nivel vertebral (0 corresponde a Normal/Mild y 2 a Severe).*

Las condiciones no son independientes entre sí. La correlación de la severidad promedio por paciente va de 0.43 a 0.66 (Figura 5), y la relación más fuerte es entre la estenosis del canal y la subarticular, que son estructuras vecinas. A nivel de paciente (Figura 6), la mitad de los estudios (50.4%) no tiene ninguna etiqueta Severe, pero un 12.1% tiene cinco o más al mismo tiempo. La degeneración es entonces un proceso del paciente completo, y no 25 eventos aislados.

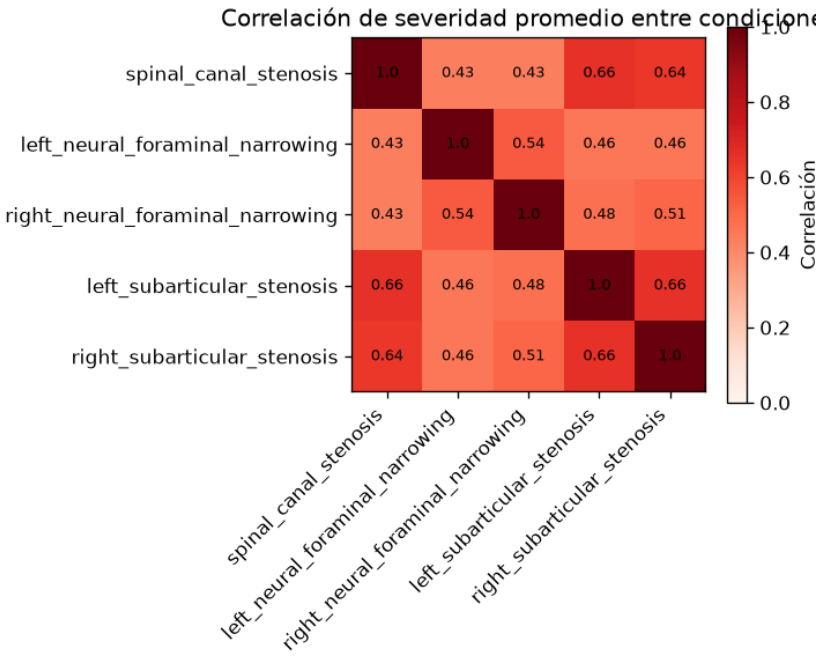


Figura 5. *Correlación de la severidad promedio por paciente entre las cinco condiciones.*

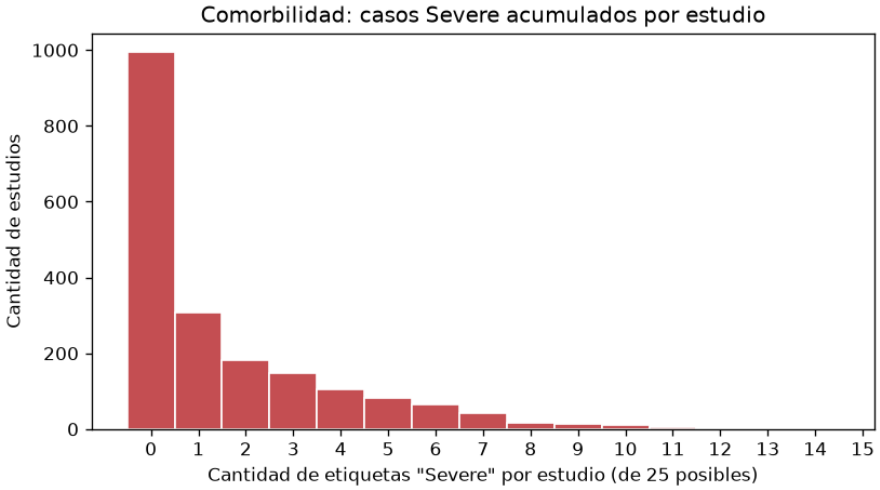


Figura 6. *Cantidad de etiquetas Severe por estudio, de 25 posibles.*

Por último, se analizó dónde se marcaron las anotaciones. Cada condición se anotó casi siempre en un solo tipo de serie: el canal en Sagittal T2/STIR, el foramen en Sagittal T1 y el receso subarticular en Axial T2 (Figura 7). En los cortes sagitales la coordenada y crece al bajar por la columna, de modo que también refleja el nivel vertebral. Esto anticipa que las coordenadas serán variables importantes para los modelos de árboles, aunque solo indican dónde está la estructura y no cómo se ve.

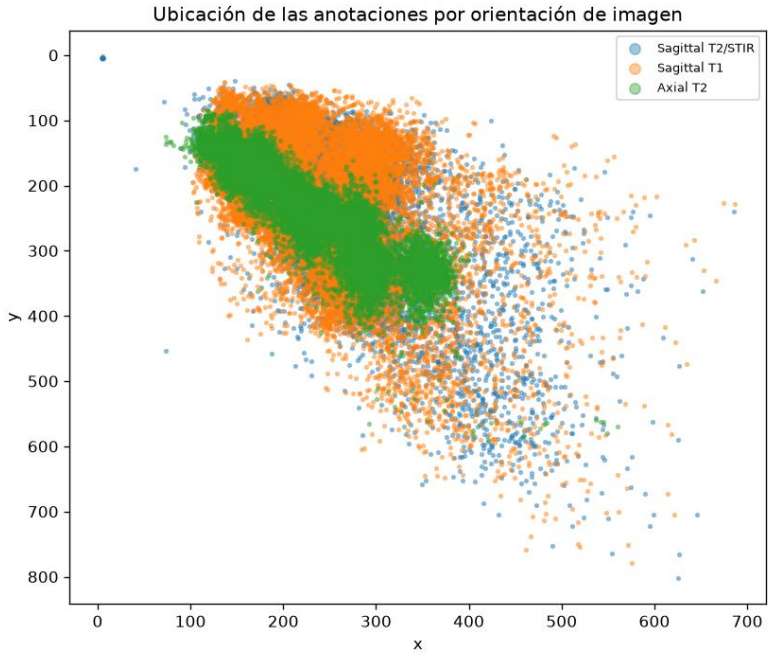


Figura 7. *Ubicación de las anotaciones en la imagen según el tipo de serie.*

5.4 Ajuste de parámetros

En todos los modelos de árboles se usaron pesos de clase balanceados, de modo que un error en la clase Severe pesa más que uno en Normal/Mild. Los hiperparámetros se eligieron con el F1 macro en el conjunto de validación, sin usar nunca el conjunto de prueba:

- **Árbol de decisión:** se probaron profundidades máximas de 3, 5, 8, 12 y sin límite, con un mínimo de 10 muestras por hoja. La mejor fue 5 (F1 macro de 0.399 en validación). Los árboles más profundos se sobreajustaban y empeoraban en validación.
- **Random Forest:** con 300 árboles se probaron profundidades de 5, 10, 20 y sin límite. La mejor fue 20 (F1 macro de 0.436), aunque sin límite el resultado fue casi igual (0.435). El modelo final se entrenó con 500 árboles y profundidad 20.
- **Gradient Boosting:** con profundidad 6 y 300 iteraciones se probaron tasas de aprendizaje de 0.01, 0.05 y 0.1. La mejor fue 0.05 (F1 macro de 0.424). El modelo final se entrenó con 500 iteraciones.

Para la ResNet50 se usó un entrenamiento en dos fases. En la primera (épocas 1 y 2) se congelaron las capas preentrenadas y solo se entrenó la parte final, con el optimizador AdamW y una tasa de aprendizaje de 0.001, para no destruir lo que la red ya sabía. En la segunda (épocas 3

a 12) se liberó toda la red con una tasa de 0.0001, decaimiento de pesos de 0.0001 y una reducción gradual de la tasa (cosine annealing). Se usaron lotes de 32 imágenes, dropout de 0.4 en la parte final y aumento de datos con rotaciones de hasta 10 grados, traslaciones de 5% y cambios de brillo y contraste de 15%. Para el desbalance se combinaron una función de pérdida con pesos de clase y un muestreo balanceado, en el que la red ve aproximadamente la misma cantidad de casos de cada clase. Se guardó el modelo de la época con mejor F1 macro en validación, con parada temprana si no mejoraba en cuatro épocas.

La Figura 8 muestra la evolución del entrenamiento. Con las capas congeladas, la red predecía casi todo como Severe (recall de Severe cercano a 1 y F1 macro menor a 0.1), efecto del muestreo balanceado. Al liberar la red, el F1 macro en validación subió de forma constante hasta 0.658 en la época 12. La pérdida de validación fue mínima en la época 5 y luego subió mientras la de entrenamiento seguía bajando, una señal de sobreajuste en las probabilidades. Aun así, el F1 macro siguió mejorando, por lo que se conservó el modelo de la última época.

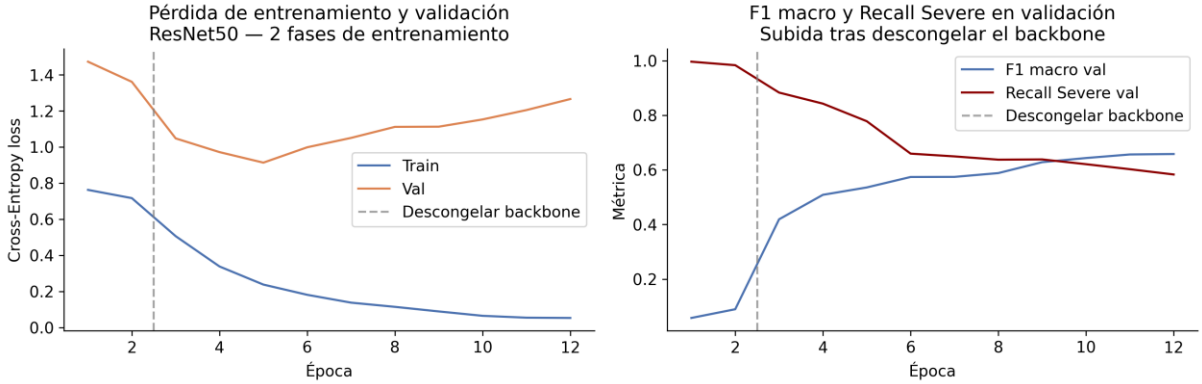


Figura 8. *Curvas de entrenamiento de la ResNet50. La línea punteada marca el momento en que se liberan las capas preentrenadas.*

5.5 Comparación de los algoritmos

Todos los modelos se evaluaron una sola vez en el conjunto de prueba, con 14,612 etiquetas de 593 pacientes que ningún modelo vio durante el entrenamiento. La Tabla 1 resume los resultados.

Modelo	Exactitud	F1 macro	Balanced acc.	Recall Severe	Kappa cuadr.	Log-loss
Clase mayoritaria	0.770	0.290	0.333	0.000	0.000	1.350
Árbol de decisión	0.505	0.393	0.512	0.657	0.197	0.189
Random Forest	0.655	0.430	0.444	0.222	0.247	0.197
Gradient Boosting	0.540	0.415	0.513	0.539	0.242	0.181
ResNet50 (imagen)	0.768	0.667	0.714	0.582	0.653	0.203

Tabla 1. *Resultados de los cinco modelos en el conjunto de prueba.*

La clase mayoritaria tiene la mayor exactitud (77.0%), pero su F1 macro es de 0.290 y su recall de Severe es cero: nunca detecta un caso grave. Esto confirma lo que se esperaba del análisis exploratorio. Los tres modelos de árboles mejoran el F1 macro a valores entre 0.39 y 0.43, pero a cambio pierden mucha exactitud, porque para encontrar casos severos marcan como Severe muchos que no lo son.

La ResNet50 es claramente el mejor modelo (Figura 9). Obtiene un F1 macro de 0.667, una balanced accuracy de 0.714 y un kappa cuadrático de 0.653, frente a 0.430, 0.513 y 0.247 del mejor modelo de árboles en cada métrica. Además, es el único modelo que mantiene la exactitud cerca de la línea base (76.8%) sin dejar de detectar las clases minoritarias. En recall de Severe la supera el árbol de decisión (0.657 contra 0.582), pero el árbol lo logra a costa de muchas falsas alarmas: su F1 de Severe es de solo 0.211, mientras que el de la ResNet50 es de 0.604.

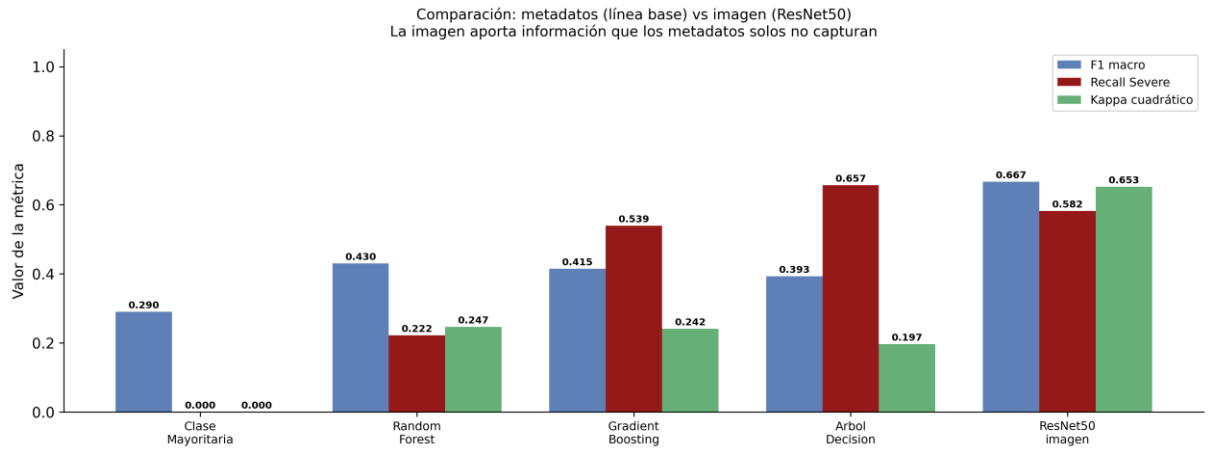


Figura 9. *F1 macro, recall de Severe y kappa cuadrático de los cinco modelos en el conjunto de prueba.*

Las matrices de confusión explican estas diferencias. En los modelos de árboles (Figura 10), los casos Severe se reparten entre las tres clases predichas: el Random Forest, por ejemplo, clasifica

como Normal/Mild el 69% de todas las etiquetas y deja pasar el 78% de los casos severos. En la ResNet50 (Figura 11), el 78% de los casos Normal/Mild y el 78% de los Moderate se clasifican bien, y cuando la red se equivoca con un caso Severe, lo clasifica como Moderate en el 93% de las ocasiones, es decir, en la clase vecina, y casi nunca como Normal/Mild. Por eso su kappa cuadrático, que castiga más los errores entre clases lejanas, es mucho más alto. Desde el punto de vista clínico, confundir un caso severo con uno moderado es mucho menos grave que enviarlo como normal.

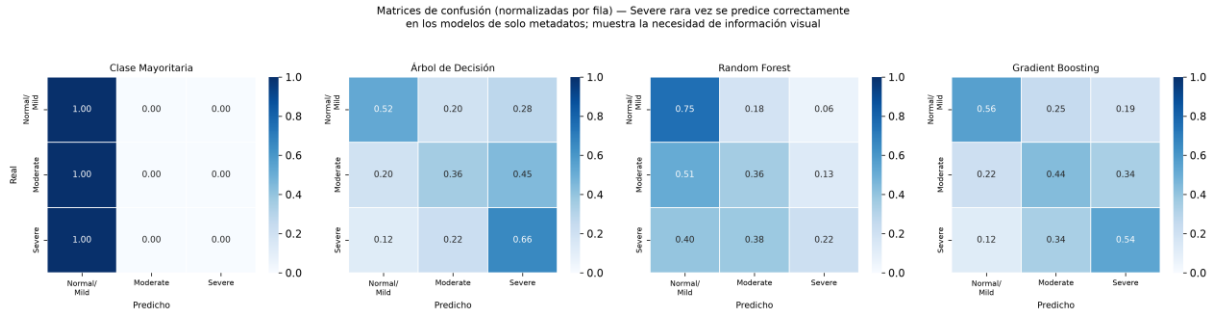


Figura 10. *Matrices de confusión normalizadas por fila de la línea base y los modelos de árboles.*

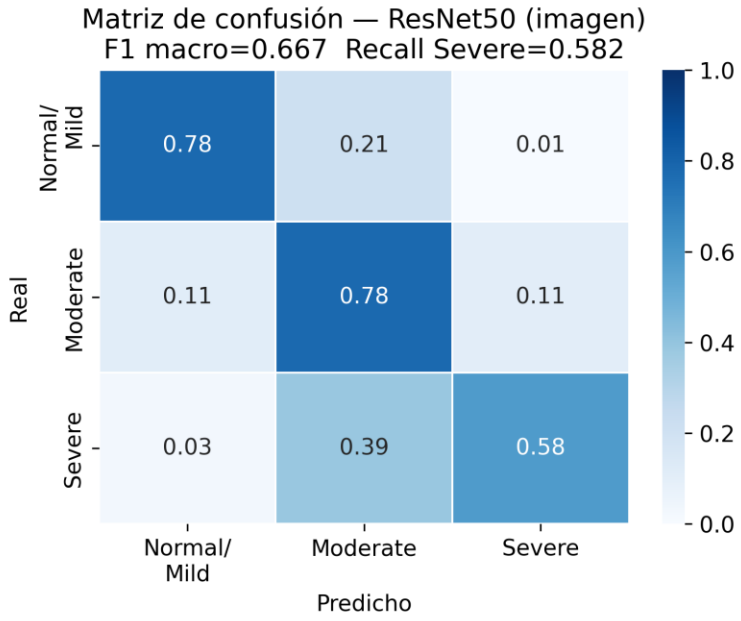


Figura 11. *Matriz de confusión normalizada por fila de la ResNet50.*

La Figura 12 muestra el F1 de cada clase en los modelos de árboles: en todos, la clase Severe es la más difícil, con valores entre 0.19 y 0.23. La importancia de variables del Random Forest (Figura 13) indica por qué: el modelo se apoya casi por completo en las coordenadas y el número

de corte, que suman cerca del 86% de la importancia. Como se vio en el análisis exploratorio, esas variables indican dónde está la estructura y funcionan como sustituto del nivel vertebral, pero no describen el tejido. Ese es el techo de los modelos que no ven la imagen, y es justamente lo que aporta la ResNet50.

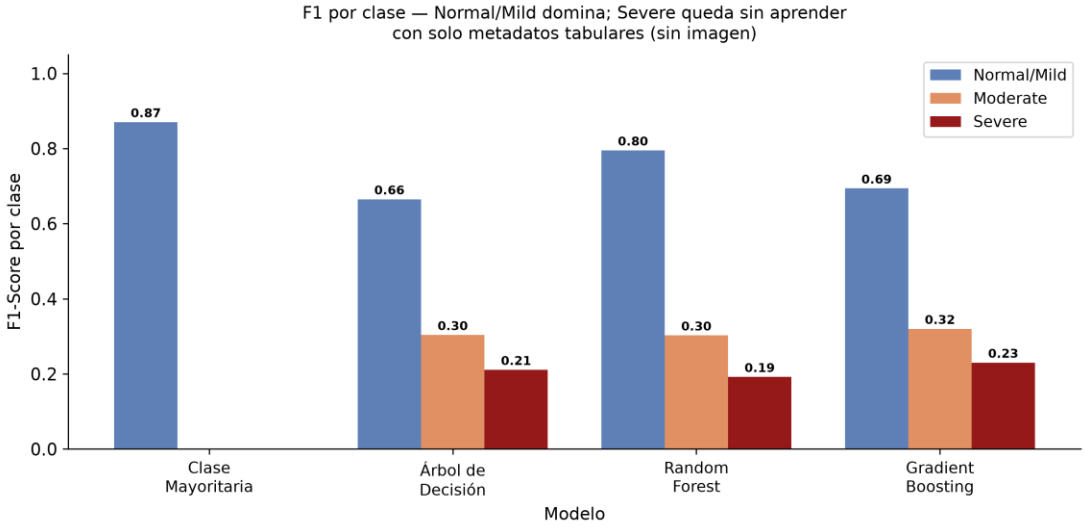


Figura 12. *F1 por clase de la línea base y los modelos de árboles.*

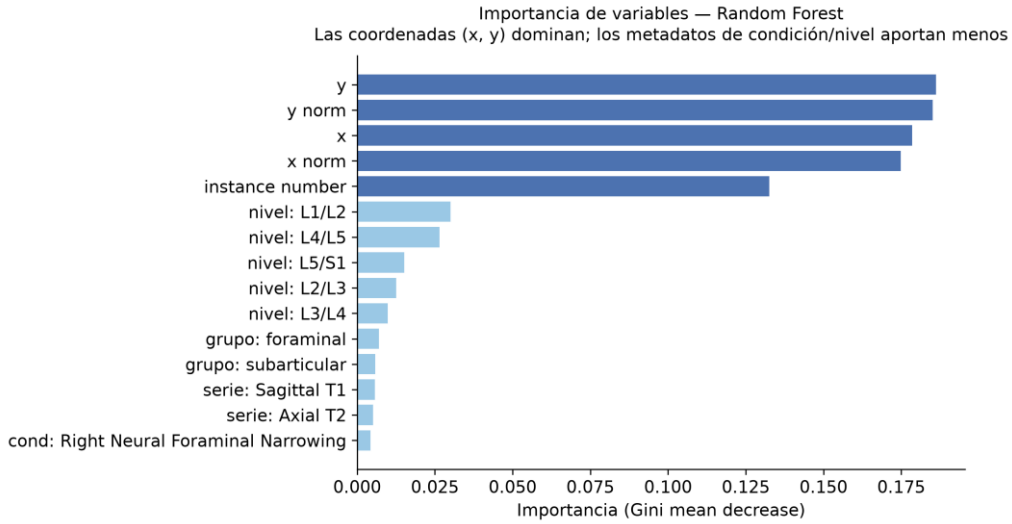


Figura 13. *Las 15 variables más importantes del Random Forest.*

En cuanto a tiempos, los modelos de árboles se entrenan en menos de un segundo y predicen en fracciones de milisegundo por muestra (Figura 14). La ResNet50 necesitó 70.7 minutos de entrenamiento en GPU y tarda 11.8 milisegundos por muestra al predecir en lote. Es un costo

mucho mayor, pero sigue siendo suficiente para uso interactivo, y compra una mejora grande en todas las métricas balanceadas.

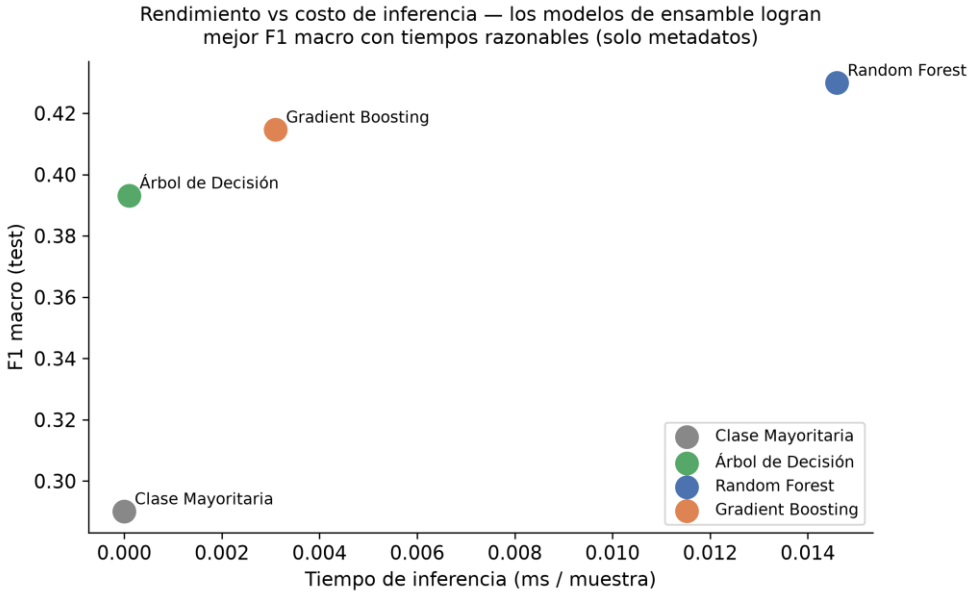


Figura 14. *Tiempo de predicción por muestra contra F1 macro de la línea base y los modelos de árboles.*

Por último, el F1 macro de cada modelo cambia muy poco entre validación y prueba (como máximo 0.009; en la ResNet50, 0.658 contra 0.667). Como ambos conjuntos son pacientes que los modelos no vieron al entrenar, esto indica que los hiperparámetros elegidos no quedaron ajustados a la validación y que los resultados de prueba son una estimación confiable del desempeño con pacientes nuevos. Con base en todo lo anterior, se seleccionó la **ResNet50** como modelo principal del sistema, y los modelos de árboles se conservaron en la aplicación como referencia para comparar.

5.6 Aplicación

Para probar los modelos se construyó una aplicación web con **Streamlit** y gráficas interactivas de **Plotly**. Se eligió Streamlit porque está escrito en Python, el mismo lenguaje de los modelos, lo que permite reutilizar directamente el código de preprocesamiento y cargar los modelos de scikit-learn y PyTorch sin construir un servidor aparte. Plotly permite que el usuario pase el cursor sobre las gráficas para ver los valores exactos, haga acercamientos y oculte series haciendo clic en la leyenda. La aplicación tiene cuatro páginas.

Diseño y colores. Se usó una escala de color con significado para las clases de severidad: azul para Normal/Mild, que transmite tranquilidad; ámbar para Moderate, como advertencia; y rojo oscuro para Severe, como alerta. Estos colores se usan igual en todas las páginas y en las figuras de este informe. Para la interfaz se eligió un azul pizarra neutro, que no se confunde con los colores de las clases, y para los modelos se usaron tonos distintos de los de severidad, con la línea base en gris.

Inicio. Presenta el problema, las tres clases de severidad con su significado, cifras generales del conjunto de datos y una gráfica del desbalance de clases. Desde aquí se accede a las demás páginas (Figura 15).



Figura 15. *Página de inicio de la aplicación.*

Explorar datos. Permite explorar los datos ya limpios con filtros por condición, nivel y severidad. Está organizada en cuatro pestañas: severidad, ubicación de las anotaciones, relaciones entre condiciones y variables de los modelos. En esta última se describen las 21 variables que usan los modelos de árboles, se muestra su distribución por clase y la importancia de cada una. Cada pestaña termina con un recuadro que explica el hallazgo y cómo influye en los modelos, para que las gráficas cuenten la historia de los datos (Figura 16).



Figura 16. *Página Explorar datos, pestaña de severidad, con su hallazgo.*

Predecir. Es la página donde se ingresan datos nuevos. El usuario sube un archivo DICOM o elige uno de ejemplo, indica la condición y el nivel, y marca el punto a evaluar haciendo clic sobre la imagen (Figura 17). Todo el preprocesamiento ocurre sin que el usuario lo note: la aplicación detecta el tipo de serie a partir del DICOM, normaliza la intensidad, hace el recorte y arma las 21 variables tabulares con los mismos parámetros que se usaron al entrenar. Se verificó que, con este preprocesamiento, los modelos de árboles obtienen exactamente las mismas métricas de prueba que en los notebooks.



Figura 17. *Página Predecir: selección de la imagen, la condición, el nivel y el punto a evaluar.*

El usuario puede elegir un modelo, varios o todos. Para cada uno se muestran la clase predicha, la probabilidad de cada clase y el tiempo que tardó en responder, junto con el recorte que vio la red (Figura 18). Más abajo, una tabla y una gráfica comparan el tiempo de cada modelo con su F1 macro en prueba, de modo que se puede comparar la eficiencia de los modelos a partir de la respuesta que dan.

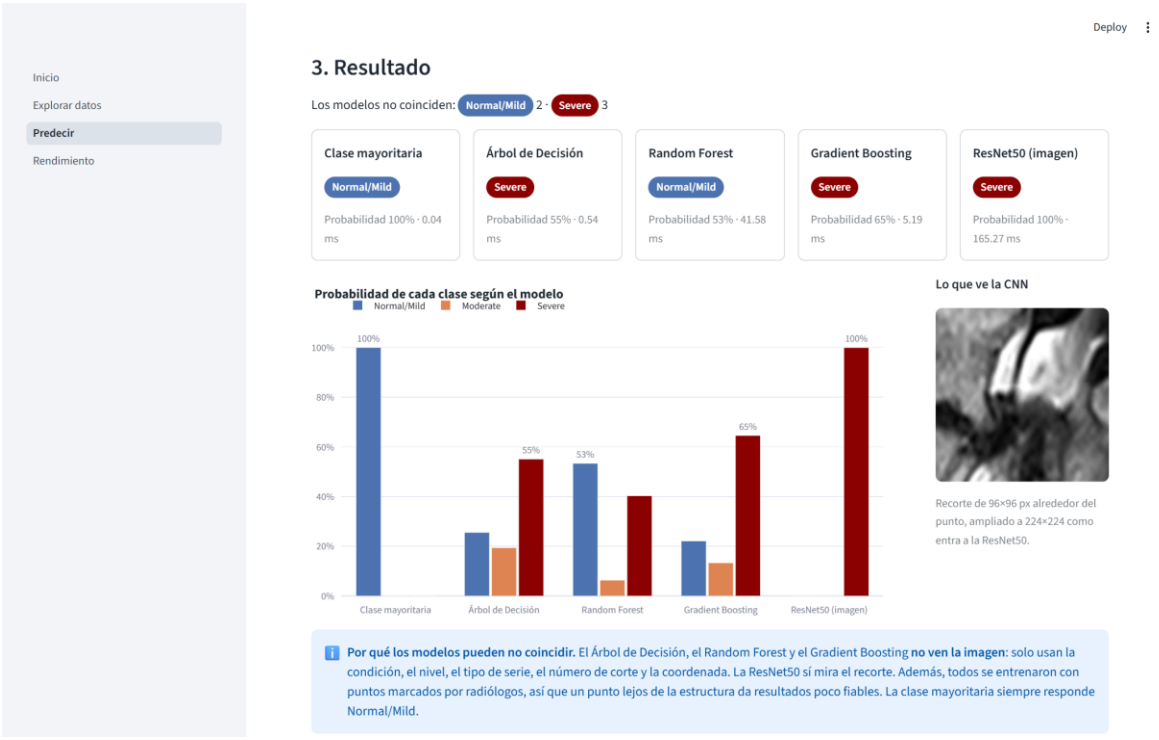


Figura 18. *Resultado de la predicción con los cinco modelos para una misma entrada.*

Rendimiento. Muestra el desempeño de cada modelo en el conjunto de prueba con gráficas interactivas: comparación de métricas, matriz de confusión del modelo elegido, F1 por clase, tiempo contra rendimiento, curvas de entrenamiento de la red y comparación entre validación y prueba. El usuario elige qué modelos comparar y, con un panel de interruptores, puede mostrar u ocultar cada gráfica (Figura 19).



Figura 19. *Página Rendimiento con el selector de modelos, los interruptores para ocultar gráficas y la tabla de métricas.*

6. Conclusiones

Sobre el análisis de los datos. Se limpiaron e integraron los tres archivos del reto y se comprobó que la calidad de los datos es alta: no hay duplicados ni categorías inválidas, y los faltantes se concentran en la estenosis subarticular de los niveles altos. El análisis exploratorio mostró tres hallazgos que guiaron el modelado: el fuerte desbalance de clases (solo 6.3% de casos severos), el gradiente de severidad a lo largo de la columna, con el máximo en L4/L5, y la relación entre condiciones dentro de un mismo paciente.

Sobre la selección de algoritmos. La revisión bibliográfica mostró que las redes convolucionales preentrenadas, aplicadas sobre recortes centrados en la estructura y combinadas con información anatómica, son el enfoque más efectivo para este problema. Siguiendo esa evidencia se eligió la ResNet50, y se usaron modelos de árboles sobre información tabular como referencia.

Sobre el entrenamiento y la comparación de modelos. Se entrenaron y ajustaron cinco modelos y se compararon con métricas adecuadas para clases desbalanceadas. La ResNet50 fue el mejor modelo, con un F1 macro de 0.667, una balanced accuracy de 0.714 y un kappa

cuadrático de 0.653, muy por encima de los modelos que no ven la imagen (F1 macro entre 0.39 y 0.43). Sus errores con los casos severos ocurren casi siempre hacia la clase vecina, lo que la hace más útil desde el punto de vista clínico. Los modelos de árboles mostraron que la posición del punto y el nivel vertebral contienen información, pero que sin la imagen hay un techo que no se puede superar. La métrica más importante para la práctica clínica, el recall de Severe, quedó en 0.582 para la red, por lo que todavía cerca de cuatro de cada diez casos severos se clasifican como moderados.

Sobre la aplicación. Se construyó una aplicación que prepara automáticamente una entrada nueva, la clasifica con uno o todos los modelos, permite explorar los datos limpios y muestra el rendimiento de cada algoritmo con gráficas interactivas que se pueden ocultar. Se verificó que el preprocesamiento de la aplicación reproduce los resultados del entrenamiento.

Trabajo futuro. Los resultados podrían mejorar entrenando con más pacientes, por ejemplo con validación cruzada agrupada por paciente, y usando varios cortes alrededor del punto en lugar de uno solo. También sería útil un modelo que analice el estudio completo, ya que el análisis exploratorio mostró que la severidad de un nivel está relacionada con la de los niveles y condiciones vecinas. Por último, el sistema depende de que el punto a evaluar esté bien marcado, por lo que un paso de localización automática de las estructuras lo haría más fácil de usar.

7. Referencias

Bharadwaj, U. U., Christine, M., Li, S., Chou, D., Pedoia, V., Link, T. M., Chin, C. T., y Majumdar, S. (2023). Deep learning for automated, interpretable classification of lumbar spinal stenosis and facet arthropathy from axial MRI. European Radiology, 33(5), 3435-3443. https://doi.org/10.1007/s00330-023-09483-6

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5-32. https://doi.org/10.1023/A:1010933404324

Buda, M., Maki, A., y Mazurowski, M. A. (2018). A systematic study of the class imbalance problem in convolutional neural networks. Neural Networks, 106, 249-259. https://doi.org/10.1016/j.neunet.2018.07.011

Cleveland Clinic. (2023, 8 de septiembre). Degenerative disk disease. https://my.clevelandclinic.org/health/diseases/16912-degenerative-disk-disease

Cohen, J. (1968). Weighted kappa: Nominal scale agreement with provision for scaled disagreement or partial credit. Psychological Bulletin, 70(4), 213-220. https://doi.org/10.1037/h0026256

Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., y Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. En 2009 IEEE Conference on Computer Vision and Pattern Recognition (pp. 248-255). IEEE. https://doi.org/10.1109/CVPR.2009.5206848

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5), 1189-1232. https://doi.org/10.1214/aos/1013203451

Hallinan, J. T. P. D., Zhu, L., Yang, K., Makmur, A., Algazwi, D. A. R., Thian, Y. L., Lau, S., Choo, Y. S., Eide, S. E., Yap, Q. V., Chan, Y. H., Tan, J. H., Kumar, N., Ooi, B. C., Yoshioka, H., y Quek, S. T. (2021). Deep learning model for automated detection and classification of central canal, lateral recess, and neural foraminal stenosis at lumbar spine MRI. Radiology, 300(1), 130-138. https://doi.org/10.1148/radiol.2021204289

Hashim, K. (2006, 6 de noviembre). Diagnóstico de la enfermedad degenerativa del disco lumbar. Spine-health. https://www.spine-health.com/es/condiciones/enfermedad-degenerativa-disco/diagnostico-enfermedad-degenerativa-disco-lumbar

He, K., Zhang, X., Ren, S., y Sun, J. (2016). Deep residual learning for image recognition. En 2016 IEEE Conference on Computer Vision and Pattern Recognition (pp. 770-778). IEEE. https://doi.org/10.1109/CVPR.2016.90

Jamaludin, A., Kadir, T., y Zisserman, A. (2017). SpineNet: Automated classification and evidence visualization in spinal MRIs. Medical Image Analysis, 41, 63-73. https://doi.org/10.1016/j.media.2017.07.002

Katz, J. N., y Harris, M. B. (2008). Lumbar spinal stenosis. The New England Journal of Medicine, 358(8), 818-825. https://doi.org/10.1056/NEJMcp0708097

LeCun, Y., Bengio, Y., y Hinton, G. (2015). Deep learning. Nature, 521(7553), 436-444. https://doi.org/10.1038/nature14539

Lee, S., Lee, J. W., Yeom, J. S., Kim, K.-J., Kim, H.-J., Chung, S. K., y Kang, H. S. (2010). A practical MRI grading system for lumbar foraminal stenosis. American Journal of Roentgenology, 194(4), 1095-1098. https://doi.org/10.2214/AJR.09.2772

Litjens, G., Kooi, T., Bejnordi, B. E., Setio, A. A. A., Ciompi, F., Ghafoorian, M., van der Laak, J. A. W. M., van Ginneken, B., y Sánchez, C. I. (2017). A survey on deep learning in medical image analysis. Medical Image Analysis, 42, 60-88. https://doi.org/10.1016/j.media.2017.07.005

Lu, J.-T., Pedemonte, S., Bizzo, B., Doyle, S., Andriole, K. P., Michalski, M. H., González, R. G., y Pomerantz, S. R. (2018). DeepSPINE: Automated lumbar vertebral segmentation, disc-level designation, and spinal stenosis grading using deep learning. Proceedings of Machine Learning Research, 85, 403-419.

Mildenberger, P., Eichelberg, M., y Martin, E. (2002). Introduction to the DICOM standard. European Radiology, 12(4), 920-927. https://doi.org/10.1007/s003300101100

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., y Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32, 8024-8035.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

Quinlan, J. R. (1986). Induction of decision trees. Machine Learning, 1(1), 81-106. https://doi.org/10.1007/BF00116251

Radiological Society of North America. (2024). RSNA 2024 Lumbar Spine Degenerative Classification [Competencia]. Kaggle. https://www.kaggle.com/competitions/rsna-2024-lumbar-spine-degenerative-classification

Shin, H.-C., Roth, H. R., Gao, M., Lu, L., Xu, Z., Nogues, I., Yao, J., Mollura, D., y Summers, R. M. (2016). Deep convolutional neural networks for computer-aided detection: CNN architectures, dataset characteristics and transfer learning. IEEE Transactions on Medical Imaging, 35(5), 1285-1298. https://doi.org/10.1109/TMI.2016.2528162

Won, D., Lee, H.-J., Lee, S.-J., y Park, S. H. (2020). Spinal stenosis grading in magnetic resonance imaging using deep convolutional neural networks. Spine, 45(12), 804-812. https://doi.org/10.1097/BRS.0000000000003377